

Propuesta de Tesina

Postulante

Marcos Pividori

Director

Dr. Lucas C. Uzal

Co-Director

Dr. Guillermo L. Grinblat

Grupo de Aprendizaje Automático y Aplicaciones, CIFASIS-CONICET

1. Situación del postulante

El alumno posee aprobadas todas las materias restantes de la carrera, excepto Práctica Profesional (R-513) a completarse en el período Junio - Septiembre del corriente año.

2. Título

Invertibilidad de un generador entrenado adversariamente.

3. Motivación y Objetivo General

Hoy en día tenemos acceso a muchísimos datos, fácilmente disponibles, donde el principal desafío es desarrollar modelos y algoritmos que puedan analizar y comprender la información contenida.

En esta dirección se enfoca el área de aprendizaje no supervisado, donde se intenta descubrir la estructura subyacente en los datos. Es decir, de manera más formal, dado un conjunto de elementos $(x_1, x_2 \dots x_N)$ de dimensionalidad p , teniendo una función de densidad de probabilidad conjunta $P(X)$, se busca descubrir la estructura relevante en esta distribución.

A diferencia del aprendizaje supervisado, en este caso no se cuenta con la ayuda de una señal supervisora que determine la respuesta correcta. En general los datos etiquetados poseen relativamente poca información, que no resulta útil para determinar los parámetros de modelos complejos como los que se intentan construir. Por lo tanto, es necesario aprender directamente de los datos en concreto.

Los modelos generativos son unos de los más prometedores en lograr este objetivo. Toman un conjunto de entrenamiento, que consiste en una gran cantidad de datos reales (millones de imágenes, oraciones, sonidos, etc) tomados de una distribución dada P_{data} y aprenden a representar una estimación de esa distribución, resultando en una distribución

probabilística P_{model} . En algunos casos esta se modela explícitamente, en otros, solo es posible generar muestras de acuerdo a P_{model} .

La intuición detrás de este enfoque es que, en la medida en que se aprenda cómo generar los datos, tendremos una mejor comprensión de las características intrínsecas de los mismos.

Los recientes avances en el entrenamiento de redes neuronales como aproximadores de funciones, potenciadas por el algoritmo de retropropagación, dieron lugar a muchas propuestas en el uso de redes neuronales para construir modelos generativos, los que suelen llamarse "*modelos generativos profundos*".

Entre los resultados más prometedores, las *Redes Adversarias Generativas* (GAN, por sus siglas en inglés) [Goodfellow2014] han sido el principal foco de investigación en los últimos años debido a que, entre otros motivos, han demostrado ser muy efectivas para generar imágenes sintéticas.

GAN establecen el problema con un juego entre dos redes: una red generadora encargada de producir datos sintéticos a partir de un vector Z de ruido dado como entrada, y una red discriminadora que diferencia entre los datos generados sintéticamente por el generador y datos reales.

La particularidad de GAN respecto a otros modelos generativos basados en redes neuronales, es que el generador (que es simplemente una red neuronal multicapa), una vez entrenado, transforma determinísticamente un vector Z de ruido, que se inyecta en la entrada de la red, en una imagen en la salida de la red. Es decir que el proceso de generación no implica ningún proceso iterativo de optimización para cada imagen sino que basta una sola propagación a lo largo de la red neuronal. Toda la variabilidad en la salida de la red es capturada por el vector Z . No hay procesos estocásticos en la transformación.

En este contexto, resulta de especial interés estudiar el espacio latente aprendido por el generador: la relación semántica entre imágenes correspondientes a valores de Z cercanos, las transformaciones causadas por desplazamientos en una dada dirección en el espacio de entrada, etc. Un primer antecedente de este tipo de análisis es el realizado por Radford et al. [Radford2015] quienes muestran que operaciones aritméticas básicas de suma y resta sobre los vectores Z tienen un correlato semántico en las imágenes generadas.

A pesar de los resultados sorprendentes en datasets limitados a un tipo particular de situación, como ser imágenes de dormitorios, rostros humanos, etc, los modelos GAN actuales no logran producir resultados convincentes cuando son entrenados en datasets de alta variabilidad, aún cuando se trabaja con datasets de imágenes de baja resolución, como CIFAR-10 (de 32x32 pxl).

Algunos resultados sugieren que las limitaciones principales estarían en las primeras capas del generador, es decir, el mapping lineal desde el vector de ruido en espacio latente a un espacio de mayor dimensionalidad (característica presente en todas las arquitecturas del estado del arte en GAN). Mientras que las capas superiores, convolucionales, operan en

gran medida condicionadas por lo que ya se decidió en las primeras capas, limitándose a ajustar detalles cada vez más finos.

Por lo tanto, deseamos analizar la dificultad del generador en aproximar la distribución real de las imágenes, en particular, en relación al rol que cumple la primer capa lineal. La propuesta es poder comparar ambas distribuciones no solo a nivel de píxeles, sino en cada representación a lo largo de la profundidad de la red. Para esto, proponemos partir de las imágenes reales e ir buscando una representación para las mismas en cada capa del generador, desde el espacio de salida hacia atrás, y de esta manera analizar si existe un valor latente en cada punto de la red que permita reconstruir la imagen original. A través de este procedimiento podremos determinar hasta qué punto son invertibles las diferentes capas del generador. Intuimos que al menos las últimas capas convolucionales serán posibles de invertir.

A la hora de invertir el generador, se estudiarán diferentes algoritmos, incluyendo recientes resultados en plantear el problema como una optimización sobre el generador, haciendo descenso por el gradiente respecto a la entrada del mismo, y otras posibilidades relacionadas a entrenar un modelo paramétrico que invierta el generador.

Luego, proponemos analizar estadísticamente la distribución de los valores latentes generados en este espacio intermedio, y compararla en relación a la distribución de las imágenes reales invertidas (suponiendo que existe representación aproximada de las mismas), buscando características que nos ayuden a comprender las limitaciones actuales.

El objetivo de esta tesina es profundizar el estudio de la relación entre las representaciones aprendidas en los diferentes niveles del generador, el modelo utilizado para el aprendizaje y los datos de entrenamiento. En particular, investigar la relación entre las distribuciones generadas y las distribuciones de las imágenes reales en cada punto de la red, y si a partir de una modificación mínima del modelo se puede lograr que el generador aproxime de manera más adecuada la distribución real. Concretamente el objetivo es evaluar, sobre imágenes de entrenamiento provenientes de los principales datasets en el estado del arte, como ser CIFAR-10 y ImageNet, la representación aprendida por el generador en diferentes niveles y establecer conclusiones respecto al desempeño de la primer capa del mismo.

4. Fundamentos y Estado de Conocimiento

Las Redes Adversarias Generativas (GAN) [Goodfellow2014] están constituidas por dos redes neuronales con roles definidos que se entrenan en un esquema competitivo. Por un lado se tiene un generador G , que es una red neuronal que recibe un vector Z de números aleatorios y devuelve una imagen. Y por otro lado el discriminador D , que es una red neuronal que recibe una imagen de entrada y devuelve un escalar en $[0,1]$. El discriminante D se entrena en forma estándar para resolver el siguiente problema de clasificación binario: dada una imagen devolver la probabilidad de que esta provenga del dataset (que sea "real"), en oposición a que sea una imagen generada por el generador G (que sea "falsa"). Este entrenamiento se consigue actualizando los parámetros de D haciendo un descenso

por gradiente estocástico sobre una función de costo estándar J para el problema de clasificación binaria. En simultáneo a cada actualización de los parámetros de D , se actualizan los parámetros de G con el objetivo opuesto: aumentar esa función de costo J con un ascenso por gradiente, es decir con el objetivo de engañar al discriminante. Este esquema de entrenamiento adversario ha despertado gran interés en el área de Deep Learning dada la calidad de los resultados obtenidos pero por sobre todo la potencialidad que implica entrenar modelos en forma no supervisada.

Las primeras versiones de GAN eran difíciles de entrenar debido al delicado equilibrio del entrenamiento adversario. Radford et al. [Radford2015] proponen una serie de recetas para entrenar en forma relativamente estable redes profundas convolucionales (DCGAN) sobre imágenes. El interés y el volumen de publicaciones sobre GAN ha crecido exponencialmente desde entonces. La investigación actual está principalmente concentrada en obtener nuevas formulaciones de GAN que resulten más estables en el entrenamiento (por ejemplo, Wassertein GAN [Arjovsky2017]) y lograr imágenes de cada vez mayor resolución y calidad [Karras2017], además de cientos de aplicaciones que surgen de entrenar redes profundas con GAN en distintas áreas [Reed2016, Yeh2016, Michelsanti2017, Zhu2017].

Mapear una imagen desde el espacio de píxeles hacia el espacio latente no es una operación trivial, ya que requiere invertir el generador, que por lo general consiste en un modelo complejo de varias capas no lineales. En principio, una misma imagen podría obtenerse de diferentes valores latentes z . En esta dirección existen trabajos con motivaciones similares a la presente tesina.

En [Dumoulin2016] [Donahue2016] proponen aprender un modelo paramétrico, llamado encoder, que asocia a cada imagen una representación en el espacio Z , entrenado en conjunto con el generador y discriminante. En este caso, el discriminante recibe pares (Imagen, Representación) de $I \times Z$, y intenta diferenciar entre pares construidos con imágenes del dataset y la codificación dada por E , y imágenes generadas por G , junto a su representación latente. Si bien muestran buenos resultados en utilizar este encoder para extraer patrones y utilizarlos en tareas de clasificación, en general las reconstrucciones no son buenas, fallando en preservar el estilo y clase de las imágenes originales. Recientemente, [Li2017] propuso métodos para mejorar las reconstrucciones.

Otras propuestas consisten en entrenar un encoder después de que el generador fue entrenado. Existen diferentes métodos de guiar este entrenamiento, por ejemplo hacer regresión en el espacio Z [Donahue2016]. Otra opción, es acoplarlos de manera opuesta y entrenarlo haciendo regresión en el espacio de imágenes [Luo2017].

Estos enfoques en general tienen la desventaja de requerir el entrenamiento de un tercer modelo (encoder) incrementando el número de parámetros a aprender y posibilidades de sobreajuste del encoder sobre los ejemplos sobre los que es entrenado, y por lo tanto no sea aplicable sobre imágenes correspondientes a una distribución distinta. Por ejemplo si se utilizan ejemplos sintéticos en el entrenamiento, pero se lo desea aplicar luego sobre imágenes reales. Por lo tanto, el hecho de introducir un modelo complejo para invertir el generador hace que su valor como herramienta de diagnóstico para evaluar GAN sea discutible.

En [Creswell2018] los autores proponen reconstruir el vector Z^* que da origen a una determinada imagen X realizando un descenso por el gradiente. Básicamente utilizan el gradiente del generador G con respecto a un vector Z inicializado al azar sobre la distribución del espacio Z , siempre que el grafo computacional de G esté disponible. El proceso de optimización es independiente para cada imagen, lo que permite realizarlo en paralelo para muchas imágenes, de manera eficiente.

Al no requerir el entrenamiento de ningún parámetro específico asociado al generador, a diferencia de otros métodos que implican entrenar un encoder, se puede utilizar el mismo procedimiento para evaluar y comparar la representación aprendida por diferentes generadores. Por ejemplo, los casos que no sea posible encontrar un valor adecuado para z , pueden considerarse como un indicio de que el generador no es capaz de modelar toda la imagen, o al menos ciertos atributos de la misma.

En este caso muestran resultados obtenidos sobre el dataset MNIST (dígitos escritos a mano) donde la imagen generada por el Z recuperado mantiene el estilo y identidad del dígito original, y de igual manera lo realizan con otros datasets específicos a un tipo particular de situación.

En [Lipton2017] proponen utilizar una variante llamada "stochastic clipping" y muestran que se obtienen muy buenos resultados, pudiendo invertir el 100% de las imágenes sintéticas a su valor latente original, y que para imágenes nuevas tiende a retornar valores únicos.

A diferencias de estos trabajos, nuestro objetivo es trabajar sobre datasets de más amplia variabilidad, que incluyan diferentes clases de objetos en diferentes situaciones, como ser Cifar-10 o ImageNet, los cuales tienen una complejidad mayor. Además, proponemos extender este mecanismo de inversión hacia las diferentes representaciones intermedias del generador. En particular, la representación aprendida luego de la primer capa lineal.

5. Objetivos Específicos

En primer lugar, proponemos analizar la invertibilidad del generador hasta el espacio de la primera capa, en comparación con la dificultad de invertir el espacio latente. Intuimos que las últimas capas, convoluciones transpuestas, se podrán invertir sin problemas a un grado de precisión arbitraria. Considerar diferentes métodos disponibles en la literatura y determinar los más acordes a este trabajo, buscando alternativas eficientes que nos permitan invertir grandes datasets en un tiempo razonable. También, determinar la invertibilidad en datasets independientes, sobre los que no fue entrenado el generador, y por lo tanto incluyan nuevas clases de imágenes.

Una vez logradas invertir las imágenes hasta el espacio de la primera capa, realizar un estudio estadístico de la distribución de las codificaciones de las imágenes invertidas en relación a la distribución de los codificaciones generadas en ese mismo espacio por el Generador. Intentar visualizar las diferencias más significativas entre las dos distribuciones

a través del análisis de varias métricas. Intentar comprender cuál es la dificultad que tiene el generador en lograr generar la misma distribución real. Determinar si las codificaciones para las imágenes reales son únicas. Analizar cómo se modifican estas distribuciones al considerar diferentes arquitecturas para el generador.

Finalmente, basándonos en los resultados de los estudios realizados, que posiblemente nos lleven a una mejor comprensión de las limitaciones del generador, intentar desarrollar una mejora ya sea en la arquitectura o en el método de entrenamiento del generador, que produzca mejores resultados finales.

6. Metodología y Plan de Trabajo

El primer paso consistirá en entrenar el generador siguiendo el procedimiento de entrenamiento Improved WGAN [Gulrajani2017], ya que es una versión que ha mostrado ser mucho más estable que formulaciones previas y constituye el estado del arte actual en generar imágenes de manera no supervisada para CIFAR-10. Para esto, se partirá de la versión oficial publicada, trabajando inicialmente con la arquitectura más simple disponible, que sigue el diseño DCGAN [Radford2015].

Los siguientes experimentos estarán asociados a considerar diferentes métodos para invertir las imágenes reales y obtener una representación en espacio latente. Para esto, en primer lugar se deberá definir una métrica adecuada para evaluar la calidad de las reconstrucciones. Se considerarán variantes no solo a nivel de píxeles (error cuadrático medio, distancia absoluta, etc), sino también otras alternativas que incluyan comparaciones a un nivel semántico más alto como ser los patrones extraídos por un clasificador, o discriminante.

Se realizarán algunos intentos en entrenar un encoder con una arquitectura similar a la del generador, pero de manera opuesta, considerando diferentes formulaciones para la función de costo y datos sobre los cuales entrenar (imágenes sintéticas o reales).

De igual manera, se consideran los enfoques basados en optimización sobre G haciendo descenso por el gradiente con respecto a los valores latentes z .

La ventaja de utilizar un encoder, es que permite obtener inversas de manera muy eficiente, al costo de tener que entrenar un modelo general para todas las imágenes, que termina siendo un problema más complejo que hacerlo independientemente para cada una, y por lo tanto se espera lograr peores resultados de reconstrucción. Por otro lado, planteando el problema como una optimización sobre G respecto a los valores de z , se esperan obtener mucho mejores resultados, pero requerirá de más tiempo para encontrar la solución adecuada, generalmente involucrando muchas iteraciones. Por lo tanto, se considerará también un enfoque híbrido, como se menciona en [Zhu2016], donde uno utiliza el valor inferido por el encoder como inicialización del proceso de optimización por descenso por el gradiente en z . De esta manera se reduce significativamente el número de iteraciones.

Una vez establecidos los valores de reconstrucción para el espacio z , se repetirán los experimentos para las diferentes representaciones intermedias del generador, analizando hasta qué punto se pueden representar con gran exactitud las imágenes del dataset real.

Una vez obtenidas las representaciones en este espacio para todas las imágenes de CIFAR-10, se realizarán diferentes experimentos que permitan comprender la estructura de la misma. Por ejemplo: analizar si las representaciones para la misma imagen son únicas, cuáles son los resultados de interpolar entre una representación y la otra, cómo se distribuyen las representaciones de las imágenes asociadas a una misma clase en relación al resto, etc. También, analizar las diferencias entre la distribución generada y la resultante de invertir las imágenes reales y de esta manera vislumbrar cuáles son las limitaciones actuales del generador para aproximar la distribución real.

También resultará de interés analizar hasta qué grado de precisión se pueden invertir las imágenes de otros datasets que no fueron utilizados para el entrenamiento, por ejemplo ImageNet.

Finalmente se utilizarán los resultados de estos análisis para proponer diferentes mejoras sobre el modelo original, implementarlas y evaluar los resultados obtenidos luego de ajustar hiperparámetros.

6.1 Cronograma de Trabajo

La siguiente es una estimación de los tiempos necesarios para cada una de las tareas propuestas.

1. Lectura de bibliografía relevante: 3 semanas
2. Implementación de diferentes algoritmos para invertir el generador: 2 semanas
3. Entrenamiento y obtención de la inversa para las imágenes de diferentes datasets, evaluación preliminar de las reconstrucciones obtenidas: 2 semanas
4. Análisis de las distribuciones: 2 semanas
5. Repetición de los experimentos para diferentes arquitecturas: 2 semanas
6. Análisis de las diferencias: 1 semana
7. Estudio y propuestas de mejoras en el modelo: 4 semanas
8. Escritura de la tesina: 4 semanas

7. Referencias

[Arjovsky2017] Martin Arjovsky, Soumith Chintala, and Léon Bottou. "Wasserstein gan." arXiv preprint arXiv:1701.07875 (2017).

[Creswell2018] Antonia Creswell, Anil Anthony Bharath. "Inverting The Generator Of A Generative Adversarial Network." arXiv preprint arXiv:1802.05701 (2018).

[Donahue2016] Jeff Donahue, Philip Krähenbühl, Trevor Darrell Austin "Adversarial feature learning". arXiv preprint arXiv:1605.09782 (2016).

- [Dumoulin2016] Vincent Dumoulin, Ishmael Belghazi, Ben Poole, Olivier Mastropietro, Alex Lamb, Martin Arjovsky, Aaron Courville. "Adversarially Learned Inference." arXiv preprint arXiv:1606.00704 (2016).
- [Goodfellow2014] Goodfellow, Ian, et al. "Generative adversarial nets." Advances in Neural Information Processing Systems 2014.
- [Gulrajani2017] Ishaan Gulrajani, Faruk Ahmed, Martin Arjovsky, Vincent Dumoulin, Aaron Courville "Improved Training of Wasserstein GANs." Advances in Neural Information Processing Systems 2017.
- [Karras2017] Karras, Tero, et al. "Progressive growing of gans for improved quality, stability, and variation." arXiv preprint arXiv:1710.10196 (2017).
- [Li2017] Chunyuan Li, Hao Liu, Changyou Chen, Yunchen Pu, Liqun Chen, Ricardo Henao, Lawrence Carin "Alice: Towards understanding adversarial learning for joint distribution matching." Advances in Neural Information Processing Systems. 2017
- [Lipton2017] Zachary Lipton, Subarna Tripathi "Precise recovery of latent vectors from generative adversarial networks." arXiv preprint arXiv:1702.04782 (2017).
- [Luo2017] Junyu Luo, Yong Xu, Chenwei Tang, Jiancheng Lv "Learning Inverse Mapping by Autoencoder based Generative Adversarial Nets." arXiv preprint arXiv:1703.10094 (2017).
- [Radford2015] Radford, Alec, Luke Metz, and Soumith Chintala. "Unsupervised representation learning with deep convolutional generative adversarial networks." arXiv preprint arXiv:1511.06434 (2015).
- [Reed2016] Reed, Scott, et al. "Generative adversarial text to image synthesis." arXiv preprint arXiv:1605.05396 (2016).
- [Yeh2016] Yeh, Raymond, et al. "Semantic image inpainting with perceptual and contextual losses." arXiv preprint arXiv:1607.07539 (2016).
- [Zhu2016] Jun-Yan Zhu, Philipp Krahenbuhl, Eli Shechtman, Alexei A. Efros "Generative Visual Manipulation on the Natural Image Manifold" Proceedings of European Conference on Computer Vision (2016).
- [Zhu2017] Jun-Yan Zhu, et al. "Unpaired image-to-image translation using cycle-consistent adversarial networks." arXiv preprint arXiv:1703.10593 (2017).