

Propuesta de Tesina

27 de Septiembre de 2020

Postulante: Jeremías Rodríguez
Director: Pablo M. Granitto
Codirector: Juan B. Cabral

1 Situación del Postulante

Todas las materias de la Licenciatura en Ciencias de la Computación aprobadas, estando cuatro de ellas (Tópicos Avanzados en Optimización Combinatoria y Teoría de Grafos ; Seminario de Pasantía ; Taller de Tesina e Ingeniería del Software II) en espera de ser cargadas al sistema Guaraní por demoras administrativas.

El postulante trabajará 30 horas semanales para una empresa de software durante la realización de la tesina.

2 Título

Búsqueda de mejoras en la detección automática de estrellas variables.

3 Motivación y Objetivo General

La astronomía está atravesando una profunda transformación debido al desarrollo de modernos telescopios terrestres y satelitales, que han impulsado la realización de grandes relevamientos astronómicos. Ante el enorme aumento en la cantidad y calidad de los datos generados, las técnicas de minería de datos y aprendizaje automatizado han comenzado a jugar un rol muy importante a la hora de analizar, resumir y extraer información de modernos datasets astronómicos.

“Vista Variables in the Via Lactea (VVV)” es un relevamiento público del infrarrojo cercano que cubrió $\sim 520 \text{ deg}^2$ del disco y bulbo galáctico, utilizando el telescopio VISTA en Paranal, Chile [1]. El VVV relevó $\sim 10^9$ estrellas en las bandas ZYJHK durante un período de 5 años, teniendo entre sus principales objetivos la realización de un mapa tridimensional del bulbo galáctico.

En este contexto, las estrellas variables de tipo RR Lyrae son una poderosa herramienta para obtener distancias a poblaciones de estrellas en la Vía Láctea, debido a que satisfacen una relación entre sus períodos y sus luminosidades absolutas que permite estimar distancias. Sin embargo, a causa de la inmensa cantidad de información generada, la clasificación manual se vuelve impracticable. Se requiere, por lo tanto, un método automatizado para identificar estrellas variables de tipo RR Lyrae de entre las $10^6 - 10^7$ estrellas variables que se espera encontrar en el área explorada.

Investigaciones recientes han mostrado que algoritmos de aprendizaje automatizado basados en ensembles de árboles tienen un excelente desempeño en este tipo de tareas, en tanto que otros métodos tradicionales como Support Vector Machines parecen no ser tan efectivos. El objetivo de esta tesina es intentar mejorar los resultados previos en el problema de detección de RRL en la VVV, así como comprender por qué métodos basados en ensembles de árboles aparentan funcionar mejor en este tipo de datos.

4 Fundamentos y estado de conocimiento sobre el tema

Las estrellas de tipo RR Lyrae son variables intrínsecas que pertenecen al grupo de variables pulsantes. Una de sus propiedades más importantes es que se pueden utilizar como candelas estándar, y por lo tanto juegan un rol prominente en la determinación de la estructura tridimensional de nuestra Galaxia. Para una revisión actual de la física y fenomenología de estrellas pulsantes, se puede referir a [2].

“Vista Variables in the Via Lactea (VVV) ESO Public Survey” es un relevamiento del bulbo galáctico y parte del disco interno de la Vía Láctea, utilizando el telescopio VISTA. El producto final fue un atlas profundo del infrarrojo cercano en cinco pasa-bandas. Uno de los objetivos principales de la VVV es adquirir un mayor entendimiento del origen, estructura y evolución de la Vía Láctea. Para una descripción detallada de la VVV puede consultarse [1], en tanto que un artículo más reciente con énfasis en variabilidad puede consultarse en [3].

Se ha explorado el desempeño de clasificadores automatizados de estrellas variables en varios estudios previos [4] [5] [6] [7]. Los dos antecedentes más relevantes de esta tesina, [8] y [9], proponen procedimientos automatizados para clasificar RRL de subtipo ab en la VVV. En ambos trabajos fue necesario determinar si cada estrella variable es periódica o no, y en caso de serlo extraer tanto su período como su serie temporal, obteniéndose finalmente curvas de luz. En una segunda etapa, se extrae una serie de características numéricas de cada curva de luz, que serán posteriormente utilizadas para entrenar y testear métodos de aprendizaje automatizado.

En [8] se concluye que AdaBoost [10], un método basado en ensembles de

árboles, es el mejor clasificador entre una amplia selección de algoritmos de aprendizaje automatizado. Adicionalmente, en [9], se refinan las métricas de desempeño y se extiende el conjunto de características con la incorporación de pseudocolor. Nuevamente, se obtiene el mejor desempeño utilizando ensembles de árboles (Random Forest[9.1]), en contraste con métodos como SVM [11] y KNN [12].

Todos los datos producidos en [9], incluyendo curvas de luz, características y el catálogo de RRL candidatas resultante fue liberado al público a través de la herramienta Carpyncho.

5 Objetivos Específicos

- Aplicar métodos de aprendizaje automatizado para clasificar RRL en la VVV, utilizando los datos liberados en Carpyncho. En particular, se focalizará en la aplicación de Support Vector Machines, experimentando distintas técnicas de preprocesamiento, optimización de parámetros, etcétera; con el objeto de mejorar los resultados obtenidos en trabajos previos.
- Realizar un estudio comparativo entre el desempeño de SVM y Random Forest en este dataset. En particular, se busca analizar y comprender las razones por las cuales SVM tiene un desempeño aparentemente menor que ensembles de árboles.
- Potencialmente, hallar alguna optimización o mejora a los procedimientos descritos en [9].

6 Metodología y Plan de Trabajo

Se proponen los siguientes pasos a seguir:

0. Revisión del estado del arte del problema a tratar, haciendo hincapié en los dos antecedentes más relevantes ([8] y [9]). Se deberá adquirir un buen entendimiento de la naturaleza de los datos con que se trabajará, así como de las técnicas que han sido aplicadas hasta el momento.
1. Aplicar Support Vector Machines a los datos liberados en Carpyncho siguiendo la metodología descrita en [9], con objeto de obtener un desempeño “baseline” a mejorar en instancias subsecuentes. Las métricas a utilizar serán, a priori, las indicadas en el mismo paper.
2. Aplicar diversas técnicas con objeto de mejorar los resultados obtenidos previamente, incluyendo:
 - Experimentar con distintos escalados para los datos

- Evaluar distintas técnicas de optimización de hiperparámetros, incluyendo la utilización de distintos kernels.
 - Selección y eliminación de features, aplicación de proyecciones, etc.
 - Explorar distintas variantes de SVM que puedan ser más adecuadas a este problema
3. Aplicar métodos de ensembles de Árboles (RF y/o Adaboost) a los datos liberados en Carpyncho, asegurándose de obtener un desempeño que sea al menos tan bueno como en [9].
 4. Realizar un estudio comparativo de los resultados obtenidos en (2) y (3), haciendo hincapié en entender los motivos fundamentales por los que cada clasificador genera tales resultados. En esta instancia será necesario adquirir un entendimiento profundo de cómo funciona cada método, y puede que sea necesario revisar las bases teóricas que sustentan a cada uno. Posiblemente algunas de las técnicas exploradas en (2) puedan también mejorar los resultados en ensembles de árboles.
 5. Realizar una conclusión a alto nivel, evaluar futuras avenidas de trabajo y documentar el trabajo apropiadamente en un informe escrito.

6.1 Cronograma de trabajo

Comenzando en septiembre:

- Semanas 1-2-3: Paso 0 del plan anterior
- Semanas 4-5 : Paso 1 del plan anterior
- Semanas 6-7-8-9: Paso 2 del plan anterior
- Semanas 10-11-12-13: Paso 3 del plan anterior
- Semanas 14-15-16-17-18 Paso 4 del plan anterior
- Semanas 19-20: Paso 5 del plan anterior

References

- [1] Dante Minniti, P.W. Lucas, Jim Emerson, R.K. Saito, Maren Hempel, P. Pietrukowicz, A. Ahumada, M.V. Alonso, J. Alonso-García, J. Arias, Reba Bandyopadhyay, Rodolfo Barbá, B. Barbuy, L.R. Bedin, E. Bica, J. Borissova, L. Bronfman, G. Carraro, Márcio Catelan, and Manuela Zoccali. Vista variables in the via lactea (vvv): The public eso near-ir variability survey of the milky way. *New Astronomy*, 15:433, 12 2010.
- [2] Horace A. Smith Márcio Catelan. *Pulsating Stars*. Wiley-VCH, 2015.

- [3] Márcio Catelan, Istvan Dekany, Maren Hempel, and Dante Minniti. Stellar variability in the vvv survey: An update. 06 2014.
- [4] Jonas Debosscher, Luis Sarro, C. Aerts, Jan Cuypers, Bart Vandebussche, Rafael Garrido, and E. Solano. Automated supervised classification of variable stars i. methodology. *Astronomy and Astrophysics*, 475, 11 2007.
- [5] Pierre Dubath, L. Rimoldini, Maria Süveges, Jonas Blomme, M López, Luis Sarro, J. De Ridder, Jan Cuypers, Leanne Guy, I. Lecoœur, K. Nienartowicz, A. Jan, Mathias Beck, N. Mowlavi, P. Cat, Thomas Lebzelter, and L. Eyer. Random forest automated supervised classification of hipparcos periodic variable stars. *Monthly Notices of The Royal Astronomical Society - MON NOTIC ROY ASTRON SOC*, 414, 01 2011.
- [6] D. Armstrong, J. Kirk, K. Lam, J. McCormac, S. Walker, D. Brown, Hugh Osborn, D. Pollacco, and J. Spake. K2 variable catalogue: Variable stars and eclipsing binaries in k2 campaigns 1 and 0. *Astronomy and Astrophysics*, 02 2015.
- [7] Martin Paegert, Keivan Stassun, and Dan Burger. The eb factory project i. a fast, neural net based, general purpose light curve classifier optimized for eclipsing binaries. *The Astronomical Journal*, 148:31, 06 2014.
- [8] Felipe Elorrieta López, Susana Eyheramendy, Andrés Jordán, and Istvan Dekany. A machine learned classifier for rr lyrae in the vvv survey. *Astronomy & Astrophysics*, 595, 09 2016.
- [9] Juan B. Cabral, Felipe Ramos, Sebastián Gurovich, and Pablo Granitto. Automatic Catalog of RRLyrae from ~ 14 million VVV Light Curves: How far can we go with traditional machine-learning? *arXiv e-prints*, page arXiv:2005.00220, May 2020.
- [10] Yoav Freund and Robert E Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1):119 – 139, 1997.
- [11] Thomas M. Mitchell. *Machine Learning*. McGraw-Hill, Inc., USA, 1 edition, 1997.
- [12] Vladimir Vapnik. *The Nature of Statistical Learning Theory*. McGraw-Hill, 2000.